

Градиентный бустинг для вероятностного прогнозирования LoS-блокировок в промышленных сценариях сетей 5G NR

Д. А. Аветисян*, В. О. Бегишев

Аннотация

В работе рассматривается задача вероятностной оценки блокировки прямой видимости (LoS) в сетях 5G NR промышленного интернета вещей на основе методов машинного обучения. Предложена модель градиентного бустинга над решающими деревьями для прогнозирования вероятности возникновения LoS-блокировки с учётом геометрических, радиофизических и средовых параметров. Проведён численный анализ, показывающий эффективность предложенного подхода при моделировании сложной промышленной среды.

Ключевые слова

5G NR, промышленный интернет вещей, LoS-блокировка, машинное обучение, Gradient Boosting, вероятностное моделирование, радиоканал, mmWave

1. Введение

Сети 5G NR миллиметрового диапазона (mmWave) рассматриваются как ключевая технологическая основа промышленного интернета вещей (IIoT). Высокая направленность и широкая полоса частот позволяют обеспечить требования eMBB и URLLC-приложений в автоматизированных производственных системах. Однако распространение сигнала в промышленной среде существенно осложняется явлением блокировки прямой видимости (Line-of-Sight, LoS), обусловленным наличием металлоконструкций, станков и подвижных механизмов.

В работе [1] предложена аналитическая модель вероятности LoS-блокировки для промышленных mmWave-развертываний 5G NR. Модель основана на сочетании фотограмметрического анализа прозрачности отдельных машин и стохастической геометрии (Manhattan Poisson Line Process), что позволяет получить выражения для вероятности блокировки в зависимости от плотности оборудования, геометрии размещения и высоты антенн.

Несмотря на аналитическую строгость, вычисление вероятности блокировки требует интегрирования по пространственным координатам и распределению высот машин, что усложняет применение модели в задачах оптимизации и системного планирования. В настоящей работе предлагается использовать методы машинного обучения для построения модели, аппроксимирующей аналитический вероятностный функционал.

2. Аналитическая модель LoS-блокировки

Рассматривается промышленное помещение, в котором производственные линии формируют стохастическую решётчатую структуру. Размещение линий моделируется Manhattan Poisson Line Process с интенсивностями λ_x и λ_y по осям.

Information and Telecommunication Technologies and Mathematical Modeling of High-Tech Systems 2026 (ITTMM 2026), Moscow, April 13–18, 2026

*Автор, отвечающий за публикацию.

✉ yaedavid@ya.ru (Д. А. Аветисян); begishev-vo@rudn.ru (В. О. Бегишев)



© 2025 Copyright for this paper by its authors. Use permitted under Creative Commons License Attribution 4.0 International (CC BY 4.0).

Вероятность блокировки LoS для устройства, расположенного в точке (l_x, l_y) определяется выражением вида

$$p_B(l_x, l_y) = \exp(-\kappa\nu(\Lambda_x l_x + \Lambda_y l_y)), \quad (1)$$

где

- l_x, l_y - координаты расположения пользовательского устройства относительно точки размещения передатчика по осям x и y ;
- κ - коэффициент прозрачности промышленной машины, характеризующий вероятность прохождения LoS-луча через объект;
- ν - вероятность занятости ячейки промышленным оборудованием;
- Λ_x, Λ_y - эффективные интенсивности пересечений линии прямой видимости с потенциальными блокирующими объектами вдоль осей x и y .

В случае случайной высоты машин H_B интенсивности задаются интегралами:

$$\Lambda_x = \int_0^{l_x} \lambda_x (1 - F_{H_B}(f_{L,x}(x))) dx, \quad (2)$$

где

- λ_x - интенсивность линий размещения промышленного оборудования вдоль оси x , характеризующая плотность производственных линий;
- H_B - случайная величина, описывающая высоту промышленного оборудования;
- F_{H_B} - функция распределения случайной высоты промышленной машины;
- ν - вероятность занятости ячейки промышленным оборудованием;
- x - текущая координата точки пересечения линии прямой видимости с производственной линией;
- $f_{L,x}(x)$ - высота линии прямой видимости (LoS) в точке x :

$$f_{L,x}(x) = h_A - \frac{(h_A - h_U)x}{l_x}. \quad (3)$$

где

- h_A - высота передающей антенны (базовой станции);
- h_U - высота пользовательского устройства;
- x - координата точки на проекции линии прямой видимости вдоль оси x ;
- l_x - горизонтальное расстояние между передатчиком и пользовательским устройством по оси x .

Аналогичное выражение записывается для оси y .

Таким образом, итоговая вероятность блокировки представляет собой сложный нелинейный функционал от параметров среды:

$$p_B = f(d, h_A, h_U, \nu, \kappa, \lambda_x, \lambda_y, F_{H_B}). \quad (4)$$

где

- d - расстояние между передатчиком и пользовательским устройством;
- h_A - высота передающей антенны (базовой станции);
- h_U - высота пользовательского устройства;
- ν - вероятность занятости ячейки промышленным оборудованием;

- κ - коэффициент прозрачности промышленной машины, характеризующий вероятность прохождения LoS-луча через объект;
- λ_x, λ_y - интенсивности линий размещения промышленного оборудования вдоль осей x и y , характеризующие плотность производственных линий;
- H_B - случайная величина, описывающая высоту промышленного оборудования;
- F_{H_B} - функция распределения случайной высоты промышленной машины/

При многократных вычислениях (например, при оптимизации расположения базовых станций) непосредственное использование интегральной формы оказывается вычислительно затратным.

3. Постановка задачи машинного обучения

Целью является построение модели машинного обучения

$$\hat{f}(X) \approx p_B \quad (5)$$

где вектор признаков

$$X = (d, h_A, h_U, \nu, \kappa, \lambda_x, \lambda_y, H_B) \quad (6)$$

Задача формулируется как задача регрессии с ограниченным диапазоном выхода:

$$\hat{f} : \mathbb{R}^n \rightarrow [0, 1] \quad (7)$$

ML-модель должна воспроизводить поведение аналитической модели в широком диапазоне параметров.

4. Метод градиентного бустинга

В качестве аппроксиматора используется ансамблевая модель градиентного бустинга:

$$F_M(x) = \sum_{m=1}^M \gamma_m h_m(x) \quad (8)$$

где

- x - вектор входных признаков модели;
- M - количество базовых моделей (решающих деревьев) в ансамбле;
- m - номер итерации алгоритма бустинга;
- γ_m - вес (коэффициент вклада) m -й базовой модели;
- $h_m(x)$ - базовая модель на m -й итерации, решающее дерево регрессии.

Минимизируется квадратичная функция потерь:

$$L = \sum_{i=1}^N (y_i - F(x_i))^2 \quad (9)$$

где

- N - количество наблюдений в обучающей выборке;
- i - индекс наблюдения в выборке;
- y_i - истинное значение целевой переменной для i -го наблюдения;
- x_i - вектор входных признаков i -го наблюдения;

- $F(x_i)$ - значение, предсказанное моделью для i -го наблюдения.

Использован алгоритм Histogram-based Gradient Boosting, обеспечивающий высокую вычислительную эффективность при больших объёмах выборки.

Градиентный бустинг рассматривается как модель аналитического функционала, полученного в работе [1].




Рис. 1: Сравнение предсказанных и аналитических значений вероятности LoS-блокировки. Красная линия соответствует идеальному случаю $y = x$.

5. Численные эксперименты

5.1. Генерация датасета

Датасет сформирован путём вычисления вероятности LoS-блокировки на основе аналитической модели из работы [1] при различных комбинациях параметров:

- расстояние $d \in [5, 100]$ м;
- плотность занятости $\nu \in [0.1, 0.9]$;
- случайная высота машин;
- число наблюдений — до 200 000.

5.2. Результаты in-domain

Получены следующие метрики:

- среднее абсолютное отклонение $\text{MAE} \approx 0.02$,
- среднеквадратичная ошибка прогноза $\text{RMSE} \approx 0.03$,
- коэффициент детерминации (доля дисперсии целевой переменной) $R^2 \approx 0.97$.

Модель точно аппроксимирует аналитический функционал.

5.3. Out-of-distribution анализ

Обучение проводилось при $\nu \leq 0.6$, тестирование — при $\nu > 0.6$.

Результаты:

- среднее абсолютное отклонение $\text{MAE} \approx 0.05$,
- среднеквадратичная ошибка прогноза $\text{RMSE} \approx 0.07$,
- коэффициент детерминации (доля дисперсии целевой переменной) $R^2 \approx 0.88$.

Даже при смене режима плотности модель демонстрирует устойчивость.

6. Обсуждение

Предложенный подход:

1. Существенно ускоряет вычисление вероятности блокировки по сравнению с интегральной формой.
2. Сохраняет физическую интерпретируемость.
3. Устойчив к изменению плотности оборудования.
4. Может использоваться в задачах оптимизации параметров сети.

Таким образом, ML-подход расширяет аналитическую модель из работы [1], обеспечивая вычислительно эффективную аппроксимацию.

7. Заключение

В работе предложена модель градиентного бустинга для вероятностного прогнозирования LoS-блокировок в промышленных сценариях 5G NR. Модель основана на аппроксимации аналитического стохастико-геометрического функционала, что обеспечивает сочетание физической корректности и вычислительной эффективности.

В дальнейшем планируется:

- учёт динамики подвижных механизмов,
- расширение модели на временные ряды,
- использование методов интерпретации (SHAP),
- применение к реальным измерениям.

Список литературы

1. Kondratyeva, A., Ivanova, D., Begishev, V., Markova, E., Mokrov, E., Gaidamaka, Y. & Samouylov, K. Characterization of Dynamic Blockage Probability in Industrial Millimeter Wave 5G Deployments. *Future Internet* **14**, 1–20. doi:10.3390/fi14020062 (2022).
2. 3GPP. *Study on Channel Model for Frequencies from 0.5 to 100 GHz* Technical Report TR 38.901 (3rd Generation Partnership Project, 2022).
3. Rappaport, T. S., Sun, S., Mayzus, R., Zhao, H., Azar, Y., Wang, K., Wong, G. N., Schulz, J. K., Samimi, M. & Gutierrez, F. Millimeter Wave Mobile Communications for 5G Cellular: It Will Work! *IEEE Access* **1**, 335–349. doi:10.1109/ACCESS.2013.2260813 (2013).
4. Bai, T. & Heath, R. W. Coverage and Rate Analysis for Millimeter-Wave Cellular Networks. *IEEE Transactions on Wireless Communications* **14**, 1100–1114. doi:10.1109/TWC.2014.2360195 (2015).
5. Andrews, J. G., Baccelli, F. & Ganti, R. K. A Tractable Approach to Coverage and Rate in Cellular Networks. *IEEE Transactions on Communications* **59**, 3122–3134. doi:10.1109/TCOMM.2011.100411.100541 (2011).
6. Chen, T. & Guestrin, C. *XGBoost: A Scalable Tree Boosting System* в *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD)* (2016), 785–794. doi:10.1145/2939672.2939785.